
Détection de fraude financière dans un système de transactions interbancaires.

**Hamza Chergui^{1,2}, Lyliabrouk¹, Nadine Cullot¹,
Nicolas Cabioch²**

1. Laboratoire d'Informatique de Bourgogne - EA 7534

Univ. Bourgogne Franche-Comté

9, avenue Alain Savary, F-21078 Dijon - France

hamza.chergui@etu.u-bourgogne.fr

lyliabrouk, nadine.cullot@u-bourgogne.fr

2. SKAIZen Group

14, rue de Mantes, 92700 Colombes

hchergui, ncabioch@skaizengroup.fr

RÉSUMÉ. Les activités liées au blanchiment d'argent sont de plus en plus courantes. Les institutions financières se doivent d'améliorer leurs systèmes actuels jugés trop peu efficaces. Nous travaillons dans le domaine bancaire où nous analysons des transactions interbancaires internationales aux caractéristiques spécifiques d'un réseau nommé SWIFT. À travers une étude de l'état de l'art, nous montrons les limites des techniques existantes d'apprentissage automatique sur les caractéristiques de ces transactions. Nous proposons ainsi une approche de détection de transactions frauduleuses en deux étapes : (i) nous calculons de nouvelles caractéristiques spécifiques au réseau SWIFT, (ii) nous proposons une adaptation de l'algorithme de classification supervisé des K plus proches voisins (KNN) pour la détection d'anomalies. Une comparaison de nos travaux avec d'autres classifieurs sur un jeu de données réel montre l'apport et l'efficacité de notre approche.

ABSTRACT. The number of money laundering activities are increasing. Financial institutions must improve their systems judged not enough efficient. Our work is to analyse international and interbank transactions circulating in a network from a company named SWIFT. Through a study of the state-of-the-art, we expose the limits of the current machine learning techniques for the SWIFT transactions characteristics. We propose a two step fraud detection approach : (i) we compute new features related to SWIFT transactions, (ii) we propose a new metric of distance based on euclidean distance for KNN algorithm. A comparison of our work with other classifiers using a real data set prove the efficiency of our approach.

MOTS-CLÉS : apprentissage automatique, détection de fraude, finance

KEYWORDS: machine learning, fraud detection, finance

1. Introduction

La lutte contre le blanchiment d'argent est une tâche complexe pour les institutions financières. (Jensen, 1997) définit le blanchiment d'argent comme une activité criminelle consistant à dissimuler l'origine ou le propriétaire de fonds obtenus de manière illégale dans le but de rendre ces fonds légitimes. Les institutions financières, principalement les banques, possèdent des systèmes de lutte contre le blanchiment d'argent, cependant ces systèmes ne sont pas assez efficaces. Selon (Knobel, 2019) 98,9% des activités de blanchiment d'argent passent à travers les mailles du filet. Les institutions financières se doivent d'améliorer leurs systèmes sous peine de recevoir des amendes conséquentes par les régulateurs du monde financier.

Les systèmes doivent être en mesure d'analyser des transactions financières qui sont des envois d'argent entre un émetteur et un bénéficiaire. Ces transactions peuvent être internationales et interbancaires. En outre, une transaction est caractérisée par des informations telles qu'un montant, une date ou une devise. Les systèmes actuels reposent sur des listes de règles et de surveillances, ce type de système est limité car les règles peuvent être identifiées par les criminels qui adaptent alors leurs manières de frauder rendant ainsi les systèmes inefficaces.

Le blanchiment d'argent est complexe à détecter du fait qu'il peut être effectué de multiples façons. (Schott, 2006) présente plusieurs schémas de blanchiment, comme la réalisation de multiples transactions de petits montants sur des comptes anodins, ou l'achat et la vente de biens luxueux tels que des voitures ou des bijoux. De plus, les recherches sur le sujet sont mises en difficulté par l'obtention de données qui sont privées. Notre travail s'inscrit dans les travaux de recherche de l'entreprise SKAIZen Group qui vise à améliorer la détection de fraude avec des données provenant d'un réseau d'une entreprise appelé SWIFT¹. Il s'agit d'une entreprise qui met à disposition un réseau interbancaire qui propose différents services comme le transfert d'argent entre différents comptes bancaires. Ce réseau permet de réaliser des transactions financières entre plus de 11000 organismes bancaires à travers près de 200 pays. Parmi ces données transactionnelles peuvent se cacher des anomalies pouvant être liées à des activités de blanchiment d'argent. Ainsi, l'analyse de transactions interbancaires est un enjeu primordial pour les institutions financières. L'apprentissage automatique est un domaine de l'intelligence artificielle qui permet d'apprendre automatiquement à partir de données et d'améliorer les résultats grâce à une phase d'apprentissage. L'apprentissage automatique est utilisé dans plusieurs domaines comme la bourse pour prédire des séries temporelles ou analyser des profils d'utilisateurs dans le e-commerce. Actuellement, peu de travaux prennent en compte l'aspect international et les intermédiaires des transactions. Nous nous intéressons dans notre travail à l'utilisation et l'adaptation des techniques d'apprentissage automatique dans le domaine financier et plus particulièrement dans la détection de fraude dans des données transactionnelles internationales au format spécifique nommé SWIFT.

La suite de l'article est organisée de la manière suivante : dans la section 2 nous dres-

1. <https://www.swift.com/>

sons un état de l'art des techniques d'apprentissage automatique dans le domaine des fraudes financières et nous concluons cette section avec une synthèse. Après avoir expliqué les limites des techniques existantes dans la littérature pour nos types de données, nous proposons notre approche dans la section 3. Afin de la valider, nous avons réalisé des expérimentations à partir d'un jeu de données réel au sein de la section 4. Enfin, nous concluons et abordons nos perspectives de recherche dans la section 5.

2. État de l'art




FIGURE 1. *Processus des techniques d'apprentissage automatique*

Selon (Mahesh, 2020), l'apprentissage automatique est utilisé pour apprendre aux machines à manipuler les données efficacement. L'objectif des techniques d'apprentissage automatique est d'apprendre à partir des données pour en extraire des informations. Dans cet article, nous avons dressé un état de l'art des techniques d'apprentissage automatique pour la détection de fraude financière qui suivent un processus pouvant se diviser en quatre étapes. Cette section est structurée selon ces quatre étapes : la première est **l'acquisition des données** qui peut être une tâche compliquée pour certains domaines tels que la finance ou la médecine où les données sont confidentielles. Certains travaux utilisent pour cela des données synthétiques afin de réaliser les expérimentations. L'**extraction de caractéristiques** consiste à calculer de nouvelles informations à partir des caractéristiques existantes et à réduire le nombre de dimensions tout en gardant l'information contenue dans l'ensemble des caractéristiques de départ. Le **choix des algorithmes et de leurs hyper-paramètres** dépend du nombre de dimensions, du volume et de la nature des données. Enfin, dans la dernière étape **l'évaluation**, les modèles prédictifs établis à l'aide des algorithmes sont évalués avec des mesures adaptées aux algorithmes.

2.1. L'acquisition des données

Les données financières sont connues pour être confidentielles, le manque de données publiques freine les expérimentations notamment pour leurs validations et leurs comparaisons. Il existe différents formats de données selon la source des données (banque de détail, banque agricole), les volumes de données des expérimentations de la littérature sont très hétérogènes allant du millier de données jusqu'aux millions.

Dans ce contexte, la communauté scientifique s'est intéressée à la génération de données synthétiques dans le domaine de la finance. (Lopez-Rojas, Axelsson, 2012) a développé un outil (PaySim) de simulateur de paiements mobiles comprenant des paiements frauduleux. (Michalak, Korczak, 2011) détaille la manière dont il a généré ses données pour valider ses expérimentations, ce qui n'est pas le cas de nombreuses expérimentations ayant recours à des données synthétiques (Tang, Yin, 2005 ; Keyan, Tingting, 2011).

Une technique exploitée est l'utilisation de données réelles couplée à des données frauduleuses générées artificiellement. Un jeu de données financier est un ensemble de transactions avec des attributs de base comme le montant et la date. Un jeu de données de référence utilisé dans de nombreuses expérimentations de notre domaine est un ensemble de transactions réalisées avec des cartes de crédits contenant des fraudes, le jeu de données comprend 3 attributs connus qui sont la date, le montant et la classe de la transaction (frauduleuse ou non frauduleuse) et 28 autres attributs dont la signification n'est pas connue ².

Les techniques d'apprentissage supervisé requièrent des données labellisées, les transactions ont un label qui précise si cette dernière est frauduleuse. La particularité de ces jeux de données est le déséquilibre de classe entre les transactions frauduleuses et les non frauduleuses, le ratio de transactions frauduleuses avoisine habituellement 1%.

2.2. Extraction de caractéristiques

Les données nécessitent d'être traitées avant d'alimenter les algorithmes. De nombreux types de traitement existent : la normalisation, l'ajout de nouvelles caractéristiques ou la réduction de dimension.

Les données financières présentes dans la littérature sont des ensembles de transactions avec des attributs de base comme le montant, la date et les acteurs impliqués (Kumar *et al.*, 2020 ; Porwal, Mukund, 2018 ; Carcillo *et al.*, 2021). Les caractéristiques calculées à partir de ces attributs sont des informations sur les clients extraites à partir de leur historique de transactions. Des agrégats sont réalisés par période (hebdomadaire, mensuel, annuel) afin de calculer des caractéristiques sur les montants moyens des transactions réalisées par les clients ainsi que leurs fréquences (nombre de transactions faites selon une période). La plupart des approches visent à détecter des comportements frauduleux avec des transactions ayant des sommes ou des fréquences trop élevées.

De plus, le problème de déséquilibre des classes peut être moins contraignant à l'aide de techniques comme SMOTE (Chawla *et al.*, 2002) permettant de générer des fraudes supplémentaires à partir des fraudes déjà existantes dans le jeu de données. (Badal-Valero *et al.*, 2018) prouvent l'efficacité de ce type de technique dans le domaine de la détection de fraude financière, en obtenant des meilleurs résultats en utilisant l'algorithme SMOTE.

2. <https://www.kaggle.com/mlg-ulb/creditcardfraud>

Les jeux de données ayant un nombre élevé de caractéristiques peuvent être problématiques car cela augmente les temps d'entraînement. Pour les techniques de réduction de dimensions, (Bestami Yuksel *et al.*, 2020) utilisent l'algorithme PCA pour entraîner l'algorithme des K plus proches voisins et (Paula *et al.*, 2016) utilisent les auto-encodeurs (technique d'apprentissage profond) pour réduire le nombre de dimensions du jeu de données, et obtiennent un temps d'entraînement 20 fois plus rapide.

2.3. *Choix des algorithmes et de leurs hyper-paramètres*

Au sein de la littérature, de nombreux travaux se concentrent sur la comparaison d'algorithmes d'apprentissage supervisé pour déduire quel algorithme est le mieux adapté aux données et à leurs volumes (Zhang, Trubey, 2019; Lorenz *et al.*, 2020; Bestami Yuksel *et al.*, 2020).

Des auteurs proposent des nouvelles architectures (Alarab *et al.*, 2020) ou des versions améliorées d'algorithmes comme le random forest avec (Xuan *et al.*, 2018).

Des algorithmes d'apprentissage non supervisé sont utilisés pour la détection de fraude financière, comme l'approche de (Porwal, Mukund, 2018) proposant une approche basée sur l'algorithme K-means, tandis que d'autres travaux se concentrent sur la proposition de nouvelles mesures de distance pour détecter des outliers (Larik, Haider, 2011).

Les techniques d'apprentissage semi supervisé consiste à utiliser dans un premier temps les techniques d'apprentissage non supervisé pour labeliser les données avec les clusters ou outliers, puis ces données labellisées alimentent un algorithme d'apprentissage supervisé (Le Khac, Kechadi, 2010; Raza, Haider, 2011; Carcillo *et al.*, 2021).

2.4. *Évaluation des modèles*

Une fois les modèles entraînés, l'objectif est de les évaluer afin de vérifier leur efficacité, pour cela de nombreuses mesures existent telles que la précision, le rappel ou le F1-Score. Ces mesures sont utilisées dans la grande majorité des travaux d'apprentissage automatique et permettent la comparaison des travaux entre eux. Cependant, il faut prendre en compte les volumes de données et les proportions des classes car celles-ci sont importantes et peuvent ne pas apparaître dans les mesures. Enfin, il est plus difficile d'évaluer des modèles avec des jeux de données non labellisés car il est compliqué de vérifier les résultats des prédictions. Il faut avoir recours à une vérification manuelle qui est une opération pouvant être longue et imprécise.

2.5. *Synthèse*

Les travaux présentés dans l'état de l'art des techniques d'apprentissage automatique dans le domaine de la détection de fraude financière montrent des verrous pour chacune des étapes. La difficulté d'acquisition de données financières freine la comparaison et la validation des approches, l'apport des données synthétiques peut

être remis en cause par leur potentiel écart avec la réalité. Concernant l'extraction de connaissances, les travaux se focalisent sur les caractéristiques portées sur les montants et fréquences des transactions des clients, on observe un manque de travaux sur les transactions comportant des aspects internationaux et interbancaires. Pour le choix des algorithmes, il existe de nombreux travaux comparant les différents algorithmes d'apprentissage automatique. Ces derniers nous ont permis de sélectionner les plus utilisés pour notre étude. Nous avons retenu l'algorithme des K plus proches voisins en l'adaptant pour les transactions SWIFT. Ce choix s'explique par l'utilisation dans l'algorithme d'une distance adaptée aux transactions SWIFT. Cette distance nous permet d'exploiter les attributs des pays et devises des transactions et donc de proposer une solution pour la détection de fraude financière sur des transactions possédant une dimension internationale. De plus, à notre connaissance, il n'existe pas de travaux opérant avec des données du réseau SWIFT hormis l'article de (Alkhalili *et al.*, 2021) qui utilise les données SWIFT pour vérifier les transactions qui ont été bloquées car les clients figuraient dans des listes de surveillances.

En résumé, les approches présentées dans la littérature ne répondent pas aux besoins de nos données financières possédant des dimensions internationales et interbancaires, c'est pourquoi nous proposons une approche pour la détection de fraude financière sur des données SWIFT.

EC = Extraction de caractéristiques

RD = Réduction de dimensionnalité

SVM = Machine à vecteurs de support (Single Vector Machine)

NB = Classification Naïve bayésienne

RF = Forêt aléatoire (Random Forest)

KNN = K plus proches voisins (K-Nearest Neighbors)

TABLEAU 1. *Tableau comparatif des travaux de la littérature selon des critères d'analyse*

Référence (année)	Données	Algorithme	EC	RD	Types de fraudes
(Tang, Yin, 2005) (2005)	Privée	SVM	✓		Montant, Fréquence
(Lv <i>et al.</i> , 2008) (2008)	Privée	Réseau de neurones	✓		Montant, Fréquence
(Le Khac, Kechadi, 2010) (2010)	Privée	Semi-supervisé	✓		Montant, Fréquence
(Kumar <i>et al.</i> , 2020) (2018)	PaySim	Réseau Bayésien		✓	Montant
(Bestami Yuksel <i>et al.</i> , 2020) (2020)	Carte de credit	KNN		✓	Fréquence
(Alkhalili <i>et al.</i> , 2021) (2021)	SWIFT	SVM,NB,RF	✓		Montant, Pays
Notre approche	Privée	KNN	✓	✓	Montant, Fréquence, Pays, Devise

3. Approche




FIGURE 2. Schéma récapitulatif de l'approche

Nous proposons une approche permettant d'entraîner un classifieur capable d'apprendre sur un jeu de données transactionnelles labelisées. L'apprentissage prédira la classe (frauduleuse ou non frauduleuse) des transactions à partir de leurs caractéristiques.

Ce travail se déroule en deux étapes, dans un premier temps nous travaillons sur le jeu de données pour créer des nouvelles caractéristiques spécifiques aux transactions SWIFT notamment sur leur dimension internationale et interbancaire. Ensuite, nous verrons comment réduire le nombre élevé de caractéristiques avec une technique d'apprentissage profond : les auto-encodeurs. Lorsque notre jeu de données disposera d'un nombre satisfaisant de caractéristiques nous pourrons entraîner un classifieur. Nous nous sommes intéressés à l'algorithme des K plus proches voisins (KNN) que nous avons adapté aux transactions SWIFT en changeant la formule de distance.

Les transactions SWIFT ont un format spécial appelé ISO 150022 MT qui possède plusieurs types de messages MT associés à différents services. Pour nos travaux, nous nous sommes focalisés sur messages MT103 représentant un type de message utilisé par les institutions financières pour des virements d'argent internationaux.

Un message MT103 possède de nombreux champs³ dont certains sont obligatoires et d'autres facultatifs. Nous avons basé nos travaux sur un jeu de données de MT103 avec un nombre de champs réduit.

3.1. Extraction de caractéristiques

TABLEAU 2. Exemple de messages SWIFT

Émetteur	Intermédiaire	Bénéficiaire	Date	Devise	Montant
BIC0FR01	BIC0IT01	BIC0FR02	210625	EUR	15006
BIC0US03	-	BIC0GB01	210625	GBP	33065
BIC0FR04	BIC0FR06	BIC0FR05	210626	EUR	100325

Sur le tableau 2 nous avons listé les attributs SWIFT sur lesquels nous allons baser nos travaux, en étudiant ces attributs nous pouvons observer 3 acteurs : l'émetteur, l'intermédiaire et le bénéficiaire. La transaction correspond à un transfert d'argent d'un montant d'argent sur une devise réalisé à une date entre l'émetteur et le bénéficiaire. Les transactions SWIFT ont des circuits adaptés aux relations entre la banque émettrice et bénéficiaire. Si ces dernières n'ont pas de relations directes alors la transaction passera par l'intermédiaire, sinon le circuit comporte seulement l'émetteur et le bénéficiaire. Les acteurs sont identifiés par un BIC, il s'agit d'un code dont nous pouvons extraire le pays de l'institution financière.

A partir de ces attributs, nous avons calculé des caractéristiques selon différents historiques et périodes :

Caractéristiques : Nous avons choisi de retenir les caractéristiques communes aux travaux présents dans l'état de l'art c'est-à-dire celles liées aux montants et aux fréquences : montant minimum, montant maximum, montant moyen, somme des montants, latence (durée depuis la dernière transaction), le nombre de transactions réalisées, le nombre de transactions réalisées par les pays (émetteurs, intermédiaires et bénéficiaires), le nombre de transactions réalisées avec la devise de la transaction, le nombre d'intermédiaires de la transaction. Puis à l'aide d'experts métiers, nous avons sélectionné de nouvelles caractéristiques spécifiques aux transactions SWIFT telles que le nombre de transactions réalisées vers les pays acteurs ou sur les devises et des caractéristiques sur la présence ou non d'un intermédiaire.

Historique de transactions : Nous avons calculé ces caractéristiques sur différents historiques de transactions, notamment avec les différentes combinaisons possibles entre les acteurs (émetteurs, intermédiaires et bénéficiaires) dans le but d'extraire des caractéristiques concernant leurs relations.

3. <http://www.iotafinance.com/SWIFT-ISO15022-Type-de-message-MT103.html>

Période : Enfin, nous avons étudié ces caractéristiques sur 3 périodes différentes (globale, mensuelle et décade). Les variations de comportements des acteurs ou de leurs relations peuvent être des signaux de fraudes. Cependant, ces variations peuvent également s'observer sur des ensembles d'acteurs partageant la même devise ou secteur d'activité, à cause d'évènements économiques pouvant avoir des impacts sur des périodes réduites (mensuelle ou décade).

3.2. Réduction de caractéristiques

Après ce travail d'extraction de caractéristiques, nous avons constaté un nombre élevé de dimensions sur notre jeu de données, ce qui va allonger considérablement le temps d'entraînement des classifieurs ce qui est contraignant pour la partie expérimentale. Ainsi, nous avons décidé d'utiliser des techniques de réduction de dimensions. Nous avons fait le choix d'utiliser un auto-encodeur qui est un réseau de neurones ayant pour objectif d'apprendre une représentation d'un ensemble de données, on parle de représentation latente. Pour utiliser un auto-encodeur, il faut définir le nombre de couches et de neurones de l'encodeur et du décodeur. L'encodeur va permettre de réduire le nombre de dimensions des transactions, le décodeur lui va essayer de reformer la transaction de base en effectuant le travail inverse. Dans l'exemple ci-dessous, on peut définir x comme une transaction, après avoir été transformée par l'encodeur la transaction est représentée par z , enfin après le décodeur la transaction sera représentée par $\hat{x}$ qui doit avoir le même nombre de dimensions que x . Pour évaluer l'apprentissage de l'auto encodeur, on compare les représentations x et $\hat{x}$, notamment avec l'erreur quadratique moyenne. Les expérimentations seront réalisées sur la représentation latente des transactions (z).





FIGURE 3. Schéma d'un auto-encodeur

3.3. Nouvelle mesure de distance pour l'algorithme KNN

Nous avons adapté l'algorithme KNN aux transactions SWIFT. Pour rappel, l'algorithme KNN fonctionne de la manière suivante : nous commençons par calculer la distance entre le point (la transaction) à classer avec les autres points du jeu de données, puis en fonction de ses k plus proches voisins on attribue la classe la plus représentée parmi les k plus proches voisins.

Dans notre contexte, les attributs des pays émetteurs, intermédiaires et bénéficiaires ainsi que la devise jouent un rôle dans la détection d'activités de blanchiment d'argent sur les transactions circulant à travers le réseau SWIFT. Nous avons constaté que les

FIGURE 4. *Fonctionnement KNN*

transactions possédant les mêmes pays et devises peuvent avoir des comportements similaires, nous souhaitons alors rapprocher les transactions possédant les mêmes devises et pays. En effet, les transactions peuvent avoir des comportements propres à chaque devise et pays, les événements politiques et économiques peuvent entraîner des conséquences directes sur certains pays et devises. Par exemple, si une devise commence à s'effondrer comme cela peut être le cas en Russie dans le contexte actuel⁴, il faut traiter différemment les transactions dont la devise est le rouble russe et les transactions comportant des acteurs russes des autres transactions avec des devises et des acteurs de nationalité différentes. Pour cela, en considérant que nos transactions sont des vecteurs, si deux transactions possèdent la même devise ou des pays similaires, nous réduisons leur distance, dans l'autre cas on l'augmente. D'un point de vue spatiale, on regroupe les transactions pour créer des groupes avec des pays et des devises similaires.

Le calcul de distance entre deux transactions est présenté sous forme d'un algorithme ci-dessous, l'avantage de notre calcul de distance est l'utilisation de variables catégoriques. En effet, il est difficile d'associer une valeur numérique à un pays ou une devise, les algorithmes d'apprentissage automatique fonctionnent majoritairement avec des valeurs numériques. C'est pourquoi inclure ces attributs pouvant avoir un impact sur des fraudes financières est important mais c'est une pratique absente de la littérature. Nous avons réalisé des expérimentations pour fixer la valeur des seuils en fonction du F1-Score. Nous avons étudié la valeur et l'impact de chaque seuil indépendamment.

4. <https://www.la Tribune.fr/economie/international/ukraine-les-pays-occidentaux-debranchent-la-russie-du-reseau-interbancaire-swift-l-arme-nucleaire-economique-904955.html>

Algorithm 1 TS-Euclidienne

Require: Transaction $t1, t2$
 $dst \leftarrow distance(t1, t2)$
if $t1.devise == t2.devise$ **then**
 $dst \leftarrow dst * seuil_devise$
else
 $dst \leftarrow dst * (1 + seuil_devise)$
end if
if $t1.pays_emetteur == t2.pays_emetteur$ **then**
 $dst \leftarrow dst * seuil_emetteur$
else
 $dst \leftarrow dst * (1 + seuil_emetteur)$
end if
if $t1.pays_intermdiaire == t2.pays_intermdiaire$ **then**
 $dst \leftarrow dst * seuil_intermdiaire$
else
 $dst \leftarrow dst * (1 + seuil_intermdiaire)$
end if
if $t1.pays_beneficiaire == t2.pays_intermdiaire$ **then**
 $dst \leftarrow dst * seuil_intermdiaire$
else
 $dst \leftarrow dst * (1 + seuil_intermdiaire)$
end if

4. Expérimentation

Les expérimentations ont été réalisées avec un jeu de données de 200 000 transactions provenant du réseau SWIFT. Il s'agit de messages MT103 dont on a extrait les attributs présents sur le tableau 2.

Nous avons utilisé la plateforme Jupyter⁵ pour développer notre approche grâce à laquelle nous avons comparé plusieurs classifieurs à l'aide de la librairie Scikit-Learn. Nous avons utilisé un jeu de données réelles labelisées obtenu grâce à une collaboration avec l'entreprise SKAIZen Group. Comme expliqué dans l'approche, nous avons commencé nos expérimentations en ajoutant de nouvelles caractéristiques basées sur les historiques des différents acteurs et également par rapport aux pays et devises des transactions. Ces caractéristiques ont été calculées sous différentes granularités, nous donnant ainsi un nombre élevé de dimensions. Notre approche basée sur l'algorithme KNN est sensible au nombre de dimensions du jeu de données, une haute dimensionnalité rallonge de manière considérable le temps d'entraînement. Pour résoudre cela, nous avons utilisé un auto-encodeur dont la configuration a été choisie à l'aide d'expériences présentées sur le tableau 3, l'objectif est de minimiser la me-

5. <https://jupyter.org/>

sure de l'erreur quadratique moyenne symbolisant la perte d'information après la réduction de dimensions. Pour établir le nombre de couches nous avons testé plusieurs configurations avec 2, 3 et 4 couches, la configuration avec 3 couches obtient l'erreur quadratique moyenne la plus faible. Pour le nombre de neurones par couche, nous avons d'abord fixé le nombre de la première couche avec le nombre de caractéristiques d'une transaction après le processus d'extraction de caractéristiques. Pour les deux autres couches, nous avons testé plusieurs configurations, nous avons retenu celle qui comporte 210 neurones sur la première couche, 150 sur la deuxième et 20 sur la troisième (210,150,20) qui possède l'erreur quadratique moyenne la plus faible (0.0065). A l'issue de l'étape de réduction de dimensions, nous avons obtenu un jeu de données comprenant 20 caractéristiques soit 10 fois moins que le nombre de dimensions obtenu après la phase d'extraction de caractéristiques.

TABLEAU 3. Résultats Auto-Encodeur

<i>Configuration</i>	<i>Erreur quadratique moyenne</i>
(210,150,80,20)	0.0077
(210,150,80,20)	0.0074
(210,100,20)	0.0071
(210,20)	0.0069
(210,150,20)	0.0065

Pour l'entraînement de notre modèle avec l'algorithme KNN, le jeu de données a été séparé de manière à avoir 80% du jeu de données en tant que jeu d'entraînement et 20% du jeu de données en tant que jeu de test. Nous avons fait le choix d'utiliser la distance euclidienne pour la disposition spatiale de nos données, nous avons expérimenté avec d'autres distances comme la distance Manhattan ou Minkowski, mais les expériences avec la distance euclidienne obtenaient les meilleurs résultats. Pour le choix des seuils de notre mesure de distance TS-Euclidean, nous avons réalisé différentes expérimentations en faisant varier leur valeur et en évaluant selon le F1-Score, ces expérimentations sont présentées sur la figure 5 qui montre que les valeurs 0.3, 0.6, 0.5 et 0.4 sont les meilleures pour les seuils respectifs de la devise, du pays émetteur, du pays intermédiaire et du pays bénéficiaire.

Afin d'évaluer nos modèles nous nous sommes basés sur les mesures suivantes :

- La précision : ratio entre le nombre d'instances correctement prédites d'une classe par rapport au nombre d'instances de la classe.
- Le rappel : ratio entre le nombre d'instances correctement prédites d'une classe par rapport au nombre d'instances prédites de la classe.
- Le F1-Score : moyenne pondérée entre la précision et le rappel.

Nous avons décidé de comparer notre classifieur KNN-TS Euclidean avec réduction de caractéristiques avec un auto-encodeur avec les classifieurs présents dans la littérature (SVM, Naive Bayes et Random Forest). Nous avons également notre mesure de distance TS Euclidean avec d'autres distances (Euclidienne, Manhattan et Min-




FIGURE 5. Résultats des expérimentations sur les seuils

kowski). Enfin, nous avons comparé l'utilisation de l'auto-encodeur avec l'algorithme d'analyse en composantes principales (ACP). Tous ces résultats sont présentés sur le tableau 3.

TABLEAU 4. Résultats des prédictions sur le jeu de test.

	Transactions Frauduleuses		
	Précision	Rappel	F1-Score
SVM	0.73	0.19	0.13
Naive Bayes	0.02	0.40	0.03
MLP	0.55	0.23	0.32
Random Forest	0.85	0.36	0.50
KNN-TS Euclidean (ACP)	0.61	0.23	0.33
KNN Manhattan (Auto-encodeur)	0.59	0.43	0.50
KNN Minkowski (Auto-encodeur)	0.59	0.43	0.50
KNN Euclidean (Auto-encodeur)	0.62	0.44	0.51
KNN-TS Euclidean (Auto-encodeur)	0.65	0.48	0.55

Les résultats sont présentés dans le tableau 4. Lors de nos expériences nous avons observé que les résultats étaient conformes à nos attentes. Nous obtenons un meilleur rappel (0.48) et F1-Score (0.55) avec notre approche, cependant l'algorithme Random

Forest dépasse notre modèle en terme de précision. La précision d'un modèle prédictif dans la détection de fraude permet d'alléger le travail des experts qui doivent vérifier si les transactions détectées comme frauduleuses sont de fausses alertes. Quant à l'amélioration du rappel, il s'agit d'améliorer la détection de transactions frauduleuses, un bon rappel signifie qu'il y a peu de transactions frauduleuses non détectées. A travers nos expérimentations, pour la réduction de dimension nous montrons l'apport des auto-encodeurs avec une précision, un rappel et un F1-Score supérieur à un modèle utilisant les ACP. Nous comparons également trois types de distances (Euclidienne, Manhattan et Minkowski), les résultats montrent que la distance euclidienne donne les meilleurs résultats.

5. Conclusion

En conclusion, nous avons dressé un état de l'art des techniques d'apprentissage automatique pour la détection de fraude financière. Nous avons détaillé le processus de ces techniques se décomposant en quatre étapes, nous avons réalisé un parallèle avec les caractéristiques de nos données : les transactions SWIFT. Leurs dimensions internationales et interbancaires sont importantes et peuvent avoir un impact sur la détection de fraude financière. Nous montrons cela à travers notre approche basée sur les techniques d'apprentissage supervisé. Nous commençons par calculer des nouvelles caractéristiques à partir de celles présentes dans la littérature et nous en sélectionnons de nouvelles spécifiques aux transactions SWIFT. Ensuite, nous avons utilisé les auto-encodeurs pour réduire le nombre élevé de caractéristiques obtenues pour enfin entraîner le classifieur KNN. Pour cet algorithme nous avons introduit une nouvelle mesure de distance basée sur les devises et les pays présents dans les transactions. Les résultats nous permettent de valider notre approche et notre hypothèse selon laquelle les dimensions internationales des transactions SWIFT ont un impact sur la détection des fraudes financières. Pour nos travaux futurs, nous souhaitons étendre nos approches à d'autres techniques notamment basées graphes et des ontologies. Nous aimerions également tester notre approche au sein d'institutions financières.

Remerciement Ce travail est soutenu à la fois par l'entreprise SKAIZen Group et l'ANRT.

Bibliographie

- Alarab I., Prakoonwit S., Nacer M. I. (2020). Competence of graph convolutional networks for anti-money laundering in bitcoin blockchain. In *Proceedings of the 2020 5th international conference on machine learning technologies*, p. 23–27.
- Alkhalili M., Qutut M. H., Almasalha F. (2021). Investigation of applying machine learning for watch-list filtering in anti-money laundering. *IEEE Access*, vol. 9, p. 18481–18496.
- Badal-Valero E., Alvarez-Jareño J. A., Pavía J. M. (2018). Combining benford's law and machine learning to detect money laundering. an actual spanish court case. *Forensic science international*, vol. 282, p. 24–34.

- Bestami Yuksel B., Bahtiyar S., Yilmazer A. (2020). Credit card fraud detection with nca dimensionality reduction. In *13th international conference on security of information and networks*, p. 1–7.
- Carcillo F., Le Borgne Y.-A., Caelen O., Kessaci Y., Oblé F., Bontempi G. (2021). Combining unsupervised and supervised learning in credit card fraud detection. *Information sciences*, vol. 557, p. 317–331.
- Chawla N. V., Bowyer K. W., Hall L. O., Kegelmeyer W. P. (2002). Smote: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, vol. 16, p. 321–357.
- Jensen D. (1997). Prospective assessment of ai technologies for fraud detection: A case study. In *Aaai workshop on ai approaches to fraud detection and risk management*, p. 34–38.
- Keyan L., Tingting Y. (2011). An improved support-vector network model for anti-money laundering. In *2011 fifth international conference on management of e-commerce and e-government*, p. 193–196.
- Knobel A. (2019). *Swift data can be a global vantage point for tackling global money laundering*. Consulté sur <https://taxjustice.net/2019/07/11/swift-data-can-be-a-global-vantage-point-for-tackling-global-money-laundering/>
- Kumar A., Das S., Tyagi V. (2020). Anti money laundering detection using naïve bayes classifier. In *2020 ieee international conference on computing, power and communication technologies (gucon)*, p. 568–572.
- Larik A. S., Haider S. (2011). Clustering based anomalous transaction reporting. *Procedia Computer Science*, vol. 3, p. 606–610.
- Le Khac N. A., Kechadi M.-T. (2010). Application of data mining for anti-money laundering detection: A case study. In *2010 ieee international conference on data mining workshops*, p. 577–584.
- Lopez-Rojas E. A., Axelsson S. (2012). Money laundering detection using synthetic data. In *Annual workshop of the swedish artificial intelligence society (sais)*.
- Lorenz J., Silva M. I., Aparício D., Ascensão J. T., Bizarro P. (2020). Machine learning methods to detect money laundering in the bitcoin blockchain in the presence of label scarcity. In *Proceedings of the first acm international conference on ai in finance*, p. 1–8.
- Lv L.-T., Ji N., Zhang J.-L. (2008). A rbf neural network model for anti-money laundering. In *2008 international conference on wavelet analysis and pattern recognition*, vol. 1, p. 209–215.
- Mahesh B. (2020). Machine learning algorithms-a review. *International Journal of Science and Research (IJSR)*, [Internet], vol. 9, p. 381–386.
- Michalak K., Korczak J. (2011). Graph mining approach to suspicious transaction detection. In *2011 federated conference on computer science and information systems (fedcsis)*, p. 69–75.
- Paula E. L., Ladeira M., Carvalho R. N., Marzagao T. (2016). Deep learning anomaly detection as support fraud investigation in brazilian exports and anti-money laundering. In *2016 15th ieee international conference on machine learning and applications (icmla)*, p. 954–960.
- Porwal U., Mukund S. (2018). Credit card fraud detection in e-commerce: An outlier detection approach. *arXiv preprint arXiv:1811.02196*.

- Raza S., Haider S. (2011). Suspicious activity reporting using dynamic bayesian networks. *Procedia Computer Science*, vol. 3, p. 987–991.
- Schott P. A. (2006). *Reference guide to anti-money laundering and combating the financing of terrorism*. World Bank Publications.
- Tang J., Yin J. (2005). Developing an intelligent data discriminating system of anti-money laundering based on svm. In *2005 international conference on machine learning and cybernetics*, vol. 6, p. 3453–3457.
- Xuan S., Liu G., Li Z., Zheng L., Wang S., Jiang C. (2018). Random forest for credit card fraud detection. In *2018 IEEE 15th international conference on networking, sensing and control (ICNSC)*, p. 1–6.
- Zhang Y., Trubey P. (2019). Machine learning and sampling scheme: An empirical study of money laundering detection. *Computational Economics*, vol. 54, n° 3, p. 1043–1063.